KLASIFIKASIKAN CITRA MANIPULASI DEEPFAKE MENGGUNAKAN MODEL MESONET DAN ERROR LEVEL ANALYSIS (ELA)

PROPOSAL TUGAS AKHIR

SKRIPSI

Oleh:

Romal Putra Lengkong

NIM: 220211060242

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS SAM RATULANGI

TAHUN 2025

LEMBAR PERSETUJUAN CALON DOSEN PEMBIMBING

Calon dosen pembimbing yang bertanda tangan dibawah ini, menyatakan bahwa mahasiswa Program Studi S1 Teknik Informatika berikut ini :

Nama	:	
NIM	:	
Judul Proposal	:	
Tipe Tugas Akhir	:	Skripsi

Telah melakukan konsultasi dan melalui proses pembimbingan penyusunan laporan proposal. Oleh karena itu, judul beserta laporan ini direkomendasikan untuk dapat diseminarkan.

Manado, ……. 2026
Calon Dosen Pembimbing,

Nama Dosen
NIP.

DAFTAR ISI

DAFTAR ISI 3
BAB I PENDAHULUAN 4
1.1. Latar Belakang 4
1.2. Rumusan Masalah 5
1.3. Batasan Masalah 5
1.4. Tujuan Tugas Akhir 6
1.5. Manfaat Tugas Akhir 6
BAB II LANDASAN TEORI 7
2.1. Penelitian Terkait 7
2.2. Teori 10
2.2.1. Deepfake dan Generative AI 10
2.2.2. Mekanisme Dasar Kompresi Lossy JPEG 11
2.2.3. Konsep Forensik Error Level Analysis (ELA) 11
2.2.4. Arsitektur Convolutional Neural Network (CNN) MesoNet 12
2.2.5. Optimasi Global Average Pooling 2D (GAP) 12
2.2.6. Matriks Evaluasi Kinerja 13
BAB III METODOLOGI PELAKSANAAN 16
DAFTAR PUSTAKA 17

BAB I
PENDAHULUAN

1.1. Latar Belakang

Perkembangan teknologi kecerdasan buatan, khususnya *Generative AI*, telah meningkatkan kualitas manipulasi citra secara signifikan hingga melampaui kemampuan persepsi visual mata manusia (Gil & Roberto, 2023). Citra manipulasi atau *deepfake* modern kini memiliki distribusi piksel yang sangat halus sehingga memicu disrupsi informasi dan ancaman keamanan siber yang serius (Alrashoud, 2025). Ancaman ini mendesak pengembangan sistem forensik digital otomatis yang mampu memverifikasi keaslian citra secara objektif dan akurat.

Pada saat yang sama, pendekatan deteksi berbasis *deep learning* yang beredar saat ini sering kali memiliki arsitektur yang sangat kompleks dan menuntut sumber daya komputasi tinggi, sehingga kurang efisien untuk diterapkan pada skenario dunia nyata atau perangkat berspesifikasi menengah (Abbasi et al., 2025). Oleh karena itu, diperlukan pendekatan alternatif yang tidak hanya presisi, tetapi juga efisien dalam penggunaan parameter laten serta stabil terhadap variasi kualitas citra.

Sebagai solusi efisiensi komputasi, arsitektur MesoNet diperkenalkan karena rancangan konvolusinya yang ringkas namun sangat efektif dalam menangkap fitur anatomi wajah pada tingkat mesoskopik (Afchar et al., 2018). Meskipun terbukti ringan, penelitian mutakhir oleh Joshi et al. (2026) menegaskan perlunya modifikasi (*enhancement*) pada arsitektur MesoNet agar model ini lebih tangguh (*robust*) terhadap gangguan manipulasi tingkat lanjut. Melatih MesoNet murni menggunakan matriks citra RGB mentah menyimpan celah kelemahan metodologis, karena akurasi model rentan anjlok apabila citra telah mengalami kompresi berulang di internet yang mengaburkan artefak visualnya.

Untuk menjembatani kelemahan degradasi piksel tersebut, *Error Level Analysis* (ELA) diimplementasikan sebagai teknik pra-pemrosesan. ELA secara matematis menonjolkan inkonsistensi tingkat kompresi pada area yang dimanipulasi, dan terbukti sangat efektif ketika diintegrasikan sebagai penyorot fitur spasial bagi arsitektur *Convolutional Neural Network* (Sadanand et al., 2024). Kombinasi ELA

yang bertugas mengekstrak fitur artefak kompresi dengan arsitektur MesoNet yang mengklasifikasikannya diharapkan dapat menghasilkan kerangka kerja deteksi *deepfake* yang komputasionalnya efisien (*Green AI*), adaptif, dan mampu menggeneralisasi berbagai jenis pemalsuan digital secara terukur.

1.2. Rumusan Masalah

Berdasarkan parameter analisis pada latar belakang, maka rumusan masalah dalam penelitian ini dideskripsikan sebagai berikut:

1. Bagaimana proses implementasi ekstraksi fitur menggunakan Error Level Analysis (ELA) dalam mengkonstruksi input tensor berupa peta anomali kompresi dari citra mentah?
2. Bagaimana kinerja komputasional dari arsitektur MesoNet dalam mengklasifikasikan citra manipulasi deepfake ketika dilatih menggunakan matriks fitur hasil pra-pemrosesan ELA?
3. Seberapa tinggi tingkat efektivitas dan kemampuan generalisasi model hibrida ELA-MesoNet berdasarkan evaluasi kuantitatif dari Confusion Matrix (Akurasi, Presisi, Recall, dan F1-Score) pada skenario pengujian multi-dataset?

1.3. Batasan Masalah

Guna mempertahankan ketajaman fokus analitis komputasi, penelitian ini dibatasi pada ruang lingkup berikut:

1. Objek Domain Data: Eksperimen secara mutlak difokuskan pada format citra 2D (JPEG/PNG/WEBP). Penelitian tidak melakukan penarikan frame maupun pemrosesan matriks temporal pada format file video.
2. Pra-pemrosesan Forensik: Filter forensik secara eksklusif berfokus pada kalkulasi Error Level Analysis (ELA), di mana simulasi penyimpanan ulang (resave quality) akan ditetapkan statis untuk memantik pola inkonsistensi JPEG.
3. Arsitektur Model: Pemodelan berbasis kerangka kerja Keras/TensorFlow menggunakan arsitektur kompak MesoNet dengan susunan empat tingkat Convolutional Layer (Conv2D), MaxPooling2D, Dropout (0.5), dan klasifikasi biner Dense Layer.
4. Pengujian sistem diimplementasikan menggunakan kombinasi multi-dataset dari Kaggle: jayanthbottu/labeled-deepfake-image-collection, divg07/casia-20-image-

tampering-detection-dataset yang disesuaikan dalam dimensi masukan 256x256 piksel

1.4. Tujuan Tugas Akhir

Penelitian analitis ini secara terstruktur bertujuan untuk:

1. Menerjemahkan diskontinuitas algoritma kompresi citra JPEG menjadi *tensor* matriks spasial yang optimal untuk *Machine Learning* melalui implementasi forensik *Error Level Analysis* (ELA).
2. Membangun, mengkompilasi, dan mengeksekusi siklus pelatihan model arsitektur kompak MesoNet dalam lingkungan komputasi Python.
3. Menganalisis parameter ketangguhan (*robustness*) dan metrik *Confusion Matrix* dari model MesoNet ketika mendeteksi manipulasi citra pada penggabungan dataset heterogen (*cross-domain forgery*).

1.5. Manfaat Tugas Akhir

Hasil eksperimen dari skripsi ini diharapkan memberikan kontribusi sebagai berikut:

1. **Manfaat Teoritis**

   Menawarkan pembuktian empiris dalam literatur *Computer Vision* bahwa manipulasi matriks piksel dengan ELA mampu difungsikan layaknya *attention mechanism* pasif yang memandu arsitektur konvolusi dangkal (MesoNet) untuk mengenali pemalsuan tanpa harus menambah kedalaman jaringan (*deep layer*).
2. **Manfaat Praktis**

   Melahirkan konfigurasi *blueprint* detektor hoaks visual berbasis AI yang berukuran sangat kecil (parameter ringan). Efisiensi ini memungkinkan implementasi perangkat lunak pada perangkat lokal berspesifikasi perangkat keras yang terbatas (*edge computing*).

BAB II
LANDASAN TEORI

2.1. Penelitian Terkait

Penelitian ini dikonstruksi berdasarkan evaluasi analitis terhadap tujuh literatur dan publikasi ilmiah *State-of-the-Art* (SOTA) dalam ranah *Computer Vision* dan Forensik Digital guna menemukan celah penelitian (*research gap*) yang dapat disempurnakan:

No	Peneliti & Tahun	Judul / Fokus Penelitian	Model / Metode	Platform / Dataset	Hasil / Kontribusi	Keterbatasan / Gap
1	Afchar et al. (2018)	***MesoNet: A compact facial video forgery detection network***	MesoNet	Video deepfake dan Face2Face	Memperkenalkan arsitektur MesoNet yang ringan namun efektif untuk deteksi forgery pada tingkat mesoskopik	Masih berfokus pada input citra/video mentah RGB, sehingga rentan terhadap degradasi kompresi dari platform media sosial _.
2	Gunawan et al. (2017)	Deteksi manipulasi foto menggunakan ELA	Error Level Analysis (ELA)	Citra hasil manipulasi JPEG	Membuktikan bahwa kompresi ulang JPEG efektif untuk menonjolkan area manipulasi secara forensik _.	Metode ELA belum diintegrasikan dengan klasifikator deep learning yang lebih spesifik untuk deteksi wajah _.
3	Li et al. (2020)	***Celeb-DF: A large-scale challenging dataset for deepfake forensics***	Dataset deepfake	Celeb-DF	Menunjukkan bahwa deepfake modern semakin sulit dideteksi karena kualitas visualnya	Pendekatan berbasis piksel mentah sering gagal menangkap anomali manipulasi yang sangat subtil _.

No	Peneliti & Tahun	Judul / Fokus Penelitian	Model / Metode	Platform / Dataset	Hasil / Kontribusi	Keterbatasan / Gap
					makin halus .	
4	Raković (2023)	*Error level analysis (ELA)*	Analisis kompresi ulang JPEG	Citra JPEG	Menjelaskan dasar matematis ELA dalam membaca inkonsistensi kompresi melalui proses resaving _.	Masih berupa landasan teoritis, belum secara langsung diarahkan pada pipeline klasifikasi deepfake berbasis CNN _.
5	Gupta et al. (2022)	Deteksi citra edit berbasis ELA dan CNN	ELA + CNN	Dataset manipulasi gambar	Menggabungkan ELA dengan CNN untuk menangkap pola anomali pemalsuan citra secara objektif _.	Menggunakan CNN generik, belum difokuskan pada arsitektur ringan spesifik wajah seperti MesoNet .
6	Sabri & Mstafa (2026)	*Curvelet-based frequency-aware feature enhancement for deepfake detection*	Analisis domain frekuensi / Curvelet	Deepfake detection	Menegaskan bahwa artefak manipulasi tetap dapat dianalisis pada domain frekuensi tinggi _.	Transformasi curvelet relatif lebih kompleks dan lebih berat dibanding ELA dari sisi komputasi _.
7	Raza et al. (2026)	Tinjauan komprehensif teknik deteksi deepfake	Perbandingan metode deep learning	Berbagai arsitektur deepfake detection	Menunjukkan bahwa arsitektur ringan dapat memberi akurasi kompetitif dengan	Belum secara spesifik mengarah pada kombinasi ELA dengan MesoNet pada deteksi citra manipulasi wajah .

No	Peneliti & Tahun	Judul / Fokus Penelitian	Model / Metode	Platform / Dataset	Hasil / Kontribusi	Keterbatasan / Gap
					beban komputasi lebih rendah .	
8	**Das et al. (2021)**	**Peningkatan deteksi deepfake dengan dynamic face augmentation**	**Augmentasi wajah dinamis**	**Dataset deepfake**	**Membantu mengatasi class imbalance dan meningkatkan generalisasi model _.**	**Fokus pada augmentasi data, belum menyentuh peran pra-pemrosesan forensik seperti ELA _.**

Berdasarkan matriks penelitian terkait di atas, posisi penelitian ini dapat dipetakan secara jelas melalui tiga aspek fundamental:

1. **State of the Art (SOTA):** Saat ini, SOTA dalam pendeteksian *deepfake* terbagi pada dua kutub komputasi. Kutub pertama mengandalkan arsitektur CNN berskala masif (seperti XceptionNet dan Vision Transformers) yang membutuhkan sumber daya komputasi raksasa (Abbasi et al., 2025; Khan et al., 2024). Kutub kedua berfokus pada efisiensi dengan memanfaatkan fitur mesoskopik menggunakan arsitektur jaringan dangkal seperti MesoNet, yang terbukti efisien untuk implementasi pada perangkat berspesifikasi menengah (Afchar et al., 2018). Di sisi lain, metode forensik *Error Level Analysis* (ELA) telah diakui secara luas sebagai pendekatan SOTA dalam mengekstraksi inkonsistensi tingkat kompresi JPEG tanpa memerlukan citra referensi asli (Raković, 2023).
2. **Research Gap (Kesenjangan Penelitian):** Literatur menunjukkan kelemahan fatal pada arsitektur MesoNet saat dihadapkan pada citra *deepfake* yang telah mengalami kompresi berulang di platform media sosial, di mana fitur piksel mentah (RGB) akan terdistorsi dan menyebabkan tingkat akurasi model menurun secara drastis (Xia et al., 2022). Walaupun integrasi ELA dengan CNN telah diusulkan sebelumnya, mayoritas penelitian masih mengumpankan citra ELA tersebut ke dalam arsitektur CNN *general-purpose* (seperti VGG16 atau ResNet) yang tidak

didesain secara eksklusif untuk mengekstrak anomali struktur anatomi wajah (Gorle & Guttavelli, 2024; Sadanand et al., 2024).

3. **Novelty (Kebaruan Penelitian):** Kebaruan pada penelitian ini adalah hibridisasi spesifik antara prapemrosesan ELA dan arsitektur MesoNet yang telah dioptimasi ujungnya menggunakan *Global Average Pooling*. Penelitian ini tidak melatih MesoNet dengan citra RGB mentah, melainkan dengan "peta anomali" kompresi hasil ELA, yang secara fungsional memaksa CNN untuk langsung berfokus pada jejak manipulasi (bertindak sebagai *attention mechanism* fisik). Modifikasi ini dirancang untuk menghasilkan model deteksi *deepfake* dengan parameter sangat kecil (~12.137 parameter latih) yang tidak hanya tangguh secara komputasi (*Green AI*), tetapi juga kebal terhadap degradasi kompresi internet lintas domain (Das et al., 2021).

2.2.Teori

Bagian ini menguraikan landasan konseptual dan arsitektur komputasional yang mendukung penyelesaian masalah deteksi deepfake guna menghindari redundansi dari pendekatan-pendekatan konvensional sebelumnya.

2.2.1. Deepfake dan Generative AI

Gil dan Roberto (2023) menjelaskan bahwa penciptaan konten *deepfake* secara fundamental dimotori oleh pemodelan prediktif berbasis *Deep Learning*, utamanya dengan mengoperasikan *Generative Adversarial Networks* (GANs) dan arsitektur *Autoencoders* bersilangan. Dalam skema komputasinya, jaringan dipaksa memampatkan ruang laten wajah dan merekonstruksinya ke target yang berbeda, seringkali melampaui kemampuan persepsi visual mata telanjang manusia. Meskipun wajah terlihat sangat natural secara makroskopis, proses fusi piksel (*up-sampling*) secara inheren akan meninggalkan anomali struktural mikroskopis pada susunan grid matriks spasial. Jejak mikroskopis dan anomali struktural akibat proses sintesis algoritma AI ini menjadi sangat rentan dan terekspos secara jelas ketika citra digital tersebut berinteraksi dengan algoritma kompresi statis saat didistribusikan di ruang siber, khususnya pada format *lossy* seperti JPEG.

2.2.2. Mekanisme Dasar Kompresi Lossy JPEG

Teknik kompresi *Joint Photographic Experts Group* (JPEG) menggunakan skema *lossy compression* yang membuang sebagian informasi visual secara permanen. Secara algoritmik, format JPEG melakukan partisi citra ke dalam blok matriks diskrit berukuran 8x8 piksel (*Minimum Coded Units*). Setiap blok kemudian dienkode menggunakan operasi *Discrete Cosine Transform* (DCT) ke dalam domain frekuensi. Jika sebuah entitas asing (seperti wajah manipulatif AI) disisipkan ke dalam kanvas citra JPEG asli dan disimpan ulang, blok 8x8 pada area modifikasi tersebut akan kehilangan sinkronisasi dengan blok latar belakangnya (Sadanand et al., 2024). Kegagalan keselarasan atau inkonsistensi siklus kompresi antar blok matriks DCT tersebut bertindak sebagai pijakan operasional secara matematis bagi teknik forensik. Inkonsistensi ini membutuhkan alat analisis tingkat piksel, yakni *Error Level Analysis* (ELA), untuk memvisualisasikan letak manipulasi.

2.2.3. Konsep Forensik Error Level Analysis (ELA)

Raković (2023) merumuskan bahwa *Error Level Analysis* (ELA) adalah alat investigasi *blind digital forensics* yang mengeksekusi perhitungan galat dari riwayat tingkat kompresi tanpa memerlukan citra referensi asli. Metode ini mengeksploitasi laju degradasi piksel. Secara komputasi matematis, kalkulasi ELA didefinisikan melalui persamaan selisih absolut:

$$I_{ELA} = \left| I_{orig} - JQ(I_{orig}) \right| \times \gamma$$

Di mana adalah representasi *input tensor* citra mentah, merupakan algoritma *resaving* citra ke dalam kompresi JPEG dengan skala kualitas statis (umumnya 90%), operator absolut menghitung selisih margin error per piksel, dan konstanta (*enhancer gain*) akan melipatgandakan kecerahan selisih tersebut. Penskalaan ini menerangi hasil galat sehingga area manipulatif berpendar terang bagaikan *noise*

putih yang kontras. Meskipun peta anomali ELA ini sangat kontras, pembacaan manual oleh analis manusia sangat rentan terhadap subjektivitas. Oleh karena itu, peta ELA ini mutlak perlu diumpankan sebagai *tensor* masukan (sebagai *attention mechanism*) ke dalam arsitektur CNN yang dikhususkan untuk fitur wajah.

2.2.4. Arsitektur Convolutional Neural Network (CNN) MesoNet

Dalam menghadapi klasifikasi *image forgery*, arsitektur MesoNet yang didesain oleh Afchar et al. (2018) memecahkan masalah kompleksitas dengan menggunakan paradigma *shallow depth network* (jaringan konvolusi dangkal). MesoNet menargetkan observasi presisi pada area mesoskopik, yaitu tingkat fitur yang berada di antara derau mikroskopis dan batasan semantik makroskopis. Secara topologi, Meso-4 memindai matriks berdimensi 256x256 menggunakan empat blok konvolusional (Conv2D) secara berurutan. Setiap pasca-konvolusi disematkan optimasi *Batch Normalization* guna menstabilkan gradien sebaran matriks selama pelatihan, dan diaktivasi oleh fungsi *Rectified Linear Unit* (ReLU) serta *MaxPooling2D* untuk mereduksi dimensi spasial fitur gambar. Walaupun kerangka lapisan konvolusi MesoNet ini telah terbukti efisien oleh Joshi et al. (2026), lapisan klasifikasi akhirnya secara bawaan masih menggunakan perataan linear (*Flatten*). Hal ini memaksa penciptaan puluhan ribu parameter koneksi yang rawan memicu *overfitting*, sehingga menuntut intervensi rekayasa struktural lebih lanjut.

2.2.5. Optimasi Global Average Pooling 2D (GAP)

Penelitian sebelumnya kerap mengalami kegagalan akibat model yang menghafal fitur pelatihan secara membabi buta (*overfitting*), yang mayoritas dipicu oleh penggunaan fungsi operasional *Flatten* di ujung arsitektur jaringan (Das et al., 2021). Operator *Flatten* yang meratakan tensor 2D menjadi vektor 1D memaksa penciptaan ratusan ribu bobot (*weights*) saat dihubungkan ke lapisan *Dense* tersembunyi. Sebagai intervensi arsitektural *Green AI*, ujung perataan pada MesoNet disubstitusikan secara penuh menggunakan agregasi matematis *Global*

Average Pooling 2D (GAP). Metode GAP meniadakan proses penderetan linier dengan mengekstraksi satu nilai rata-rata skalar (*spatial average*) murni dari setiap lembar filter 2D matriks konvolusi. Restrukturisasi ini berhasil memangkas seluruh beban komputasi laten secara eksponensial hingga menyisakan parameter aktif yang sangat minim (~12.137 parameter), meniadakan risiko *overfitting*, dan sangat menghemat memori. Setelah kerangka komputasi MesoNet berhasil direkayasa menjadi arsitektur yang sangat ringan dan adaptif melalui GAP, model dihadapkan pada tahap pengujian. Untuk membuktikan efektivitas klasifikasi secara saintifik, kinerja model mutlak harus divalidasi menggunakan instrumen statistik prediktif.

2.2.6. Matriks Evaluasi Kinerja

Pengukuran keandalan arsitektur *Machine Learning* dalam disiplin forensik digital tidak dikuantifikasi secara perseptual, melainkan melalui distribusi statistik pada instrumen *Confusion Matrix* (Matriks Kebingungan). Tabulasi ini mengklasifikasikan inferensi sistem ke dalam *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Berdasarkan elemen tersebut, metrik analitik diturunkan ke dalam persamaan matematis:

1. **Accuracy (Akurasi):** Perhitungan proporsi ketepatan prediksi model secara keseluruhan, dirumuskan melalui

$$\frac{\mathrm{TP+TN}}{\mathrm{FP+FNTP+TN}}$$

2. **Precision (Presisi):** Kredibilitas kehati-hatian, merepresentasikan seberapa dapat dipercaya keputusan algoritma saat melabeli citra sebagai manipulasi, dirumuskan melalui

$$\frac{\mathrm{TP}}{\mathrm{TP+FP}}$$

3. **Recall (Sensitivitas):** Probabilitas daya sapu sistem, mendefinisikan seberapa banyak ancaman pemalsuan *deepfake* yang sukses teridentifikasi dari seluruh kumpulan data uji, dirumuskan melalui

$$\frac{\mathrm{TP}}{\mathrm{TP+FN}}$$

4. **F1-Score:** Perhitungan rata-rata harmonik (*harmonic mean*) yang digunakan untuk mengevaluasi ekulibrium keseimbangan kinerja model antara nilai *Precision* dan *Recall*.

BAB III
METODOLOGI PELAKSANAAN

1.1. Tempat dan waktu pelaksanaan

1.2. Alat dan bahan

1.3. Kerangka pikir

DAFTAR PUSTAKA

Afchar, D., Nozick, V., Yamagishi, J., & Echizen, I. (2018). MesoNet: A compact facial video forgery detection network. In *2018 IEEE International Workshop on Information Forensics and Security (WIFS)* (pp. 1-7). IEEE. https://doi.org/10.1109/WIFS.2018.8630761

Das, S., Seferbekov, S., Datta, A., Islam, M. S., & Amin, M. R. (2021). Towards solving the deepfake problem: An analysis on improving deepfake detection using dynamic face augmentation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops* (pp. 3776-3785). IEEE. https://doi.org/10.1109/ICCVW54120.2021.00421

Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). Generative adversarial networks. *arXiv*. https://doi.org/10.48550/arXiv.1406.2661

Gunawan, T. S., Hanafiah, S. A. M., Kartiwi, M., Ismail, N., Za'bah, N. F., & Nordin, A. N. (2017). Development of photo forensics algorithm by detecting photoshop manipulation using error level analysis. *Indonesian Journal of Electrical Engineering and Computer Science, 7*(1), 131-137. https://doi.org/10.11591/ijeecs.v7.i1.pp131-137

Gupta, A., Joshi, R., & Laban, R. (2022). Detection of tool based edited images from error level analysis and convolutional neural network. *arXiv*. https://doi.org/10.48550/arXiv.2204.09075

Li, Y., Yang, X., Sun, P., Qi, H., & Lyu, S. (2020). Celeb-DF: A large-scale challenging dataset for deepfake forensics. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 3207-3216). IEEE. https://doi.org/10.1109/CVPR42600.2020.00327

Raković, D. (2023). Error level analysis (ELA). *Tehnika, 78*(4), 445-451. https://doi.org/10.5937/tehnika2304445r

Raza, A., Basit, A., Amin, A., Arfeen, Z. A., Masud, M. I., Fayyaz, U., & Jumani, T. A. (2026). A comprehensive review of deepfake detection techniques: From traditional machine

learning to advanced deep learning architectures. *AI, 7*(2), Article 68. https://doi.org/10.3390/ai7020068

Sabri, S. A., & Mstafa, R. J. (2026). Curvelet-based frequency-aware feature enhancement for deepfake detection. *Science Journal of University of Zakho, 14*(2), 386-395.

Verdoliva, L. (2020). Media forensics and deepfakes: An overview. *IEEE Journal of Selected Topics in Signal Processing, 14*(5), 910-932. https://doi.org/10.1109/JSTSP.2020.3002101