OPTIMALISASI MODEL MESONET UNTUK KLASIFIKASI CITRA MANIPULASI DEEPFAKE

PROPOSAL TUGAS AKHIR

SKRIPSI

Oleh:

Romal Putra Lengkong

220211060242

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS SAM RATULANGI

TAHUN 2026

LEMBAR PERSETUJUAN CALON DOSEN PEMBIMBING

Calon dosen pembimbing yang bertanda tangan dibawah ini, menyatakan bahwa mahasiswa Program Studi S1 Teknik Informatika berikut ini :

Nama	:	
NIM	:	
Judul Proposal	:	
Tipe Tugas Akhir	:	Skripsi

Telah melakukan konsultasi dan melalui proses pembimbingan penyusunan laporan proposal. Oleh karena itu, judul beserta laporan ini direkomendasikan untuk dapat diseminarkan.

Manado, ……. 2026
Calon Dosen Pembimbing,

Nama Dosen
NIP

DAFTAR ISI

DAFTAR ISI 3

BAB I PENDAHULUAN 4

1.1. Latar Belakang 4

1.2. Rumusan Masalah 6

1.3. Batasan Masalah 6

1.4. Tujuan Tugas Akhir 7

1.5. Manfaat Tugas Akhir 7

BAB II LANDASAN TEORI 9

2.1. Penelitian Terkait 9

2.2. Teori 12

2.2.1. Deepfake dan Generative AI 12

2.2.2. Mekanisme Dasar Kompresi Lossy JPEG 13

2.2.3. Konsep Forensik Error Level Analysis (ELA) 13

2.2.4. Arsitektur Convolutional Neural Network (CNN) MesoNet 14

2.2.5. Optimasi Global Average Pooling 2D (GAP) 15

2.2.6. Matriks Evaluasi Kinerja 15

2.2.7. Integrasi Pra-Pemrosesan Multi-Domain pada Arsitektur MesoNet 16

BAB III METODOLOGI PELAKSANAAN 17

3.1. Tempat Dan Waktu Pelaksanaan 19

3.2. Alat dan Bahan 21

3.3. Alur Penelitian 21

DAFTAR PUSTAKA 22

BAB I
PENDAHULUAN

2.1.Latar Belakang

Transformasi digital yang masif telah menyulitkan pembedaan antara citra asli dan representasi sintetik secara visual. Kemajuan pesat dalam kecerdasan buatan generatif telah memicu eskalasi penyebaran manipulasi citra hiper-realistis atau *deepfake* (Gil et al., 2023). Fenomena ini menciptakan ancaman siber serius terhadap integritas informasi publik, yang mendesak komunitas forensik digital untuk memformulasikan sistem deteksi otomatis dengan presisi tinggi sekaligus efisiensi komputasional yang optimal. Sebagai solusi komputasi berkonsep *Green AI*, arsitektur MesoNet diperkenalkan dengan rancangan jaringan konvolusi dangkal (*shallow network*) yang dikalibrasi secara khusus untuk mengekstrak anomali anatomi wajah pada tingkat mesoskopik secara efisien (Afchar et al., 2018).

Namun, pengujian performa dasar (*baseline*) terhadap arsitektur MesoNet menyingkap sebuah kelemahan struktural saat dihadapkan pada skenario dunia nyata. Pengujian empiris pada arsitektur MesoNet murni (menggunakan masukan citra RGB mentah tanpa prapemrosesan) memperlihatkan kapasitas laten yang terbatas, di mana akurasi klasifikasi tertahan secara stagnan di kisaran 76% pada himpunan data citra mentah (*raw*). Untuk mendongkrak batasan performa tersebut, *Error Level Analysis* (ELA) kerap diimplementasikan sebagai teknik prapemrosesan (Raković, 2023). Pendekatan pra-pemrosesan ELA terbukti mampu meningkatkan akurasi arsitektur jaringan konvolusi secara signifikan hingga mencapai 96,21% pada data murni, karena metode ini secara eksplisit memvisualisasikan inkonsistensi rasio kompresi JPEG pada area wajah yang dimanipulasi (Gorle & Guttavelli, 2025)

Akan tetapi, penerapan ELA memunculkan sebuah dilema forensik (*forensic trade-off*) yang kritis ketika dievaluasi menggunakan skenario degradasi citra. Citra *deepfake* yang didistribusikan melalui media sosial secara

inheren akan mengalami kompresi *lossy* tingkat lanjut yang meratakan jejak anomali piksel. Pada skenario kompresi berat, prapemrosesan ELA terbukti sangat rentan (*fragile*), menyebabkan akurasi model anjlok drastis ke kisaran 65% akibat tereduksinya metadata anomali kompresi (Xia et al., 2022). Di sisi lain, model MesoNet murni justru menunjukkan ketahanan (*robustness*) tersendiri, meskipun akurasi maksimalnya rendah, performanya lebih stabil terhadap distorsi kompresi karena model ini mempelajari artefak spasial tingkat makro. Dilema ini menegaskan bahwa penggunaan RGB mentah tidak memiliki presisi yang memadai, sementara penggunaan ELA tunggal kehilangan ketangguhan generalisasinya pada skenario kompresi dunia nyata.

Untuk memecahkan dilema forensik tersebut tanpa mengubah struktur internal jaringan saraf, penelitian ini mengusulkan strategi Pra-Pemrosesan Multi-Domain (*Multi-Level Optimization*) pada tahap prapemrosesan data. Optimalisasi ini mengintegrasikan tiga metode analisis secara simultan ke dalam satu kesatuan kerangka kerja untuk memulihkan, menyaring, dan mengekstraksi fitur manipulasi sebelum matriks diumpankan ke dalam MesoNet. Pada level pertama, *Contrast Limited Adaptive Histogram Equalization* (CLAHE) diaplikasikan untuk menajamkan kontras lokal secara adaptif dan memulihkan ketegasan batas transisi spasial yang kabur akibat kompresi. Pada level kedua, *Spatial Rich Model* (SRM) diimplementasikan untuk menekan informasi semantik visual dan mengekstraksi sisa derau frekuensi tinggi yang menjadi representasi "sidik jari" algoritma generatif. Pada level ketiga, metode ELA digunakan untuk memvisualisasikan inkonsistensi tingkat kesalahan kompresi menjadi peta anomali diskriminatif (Nazrin et al., 2025).

Sebagai sintesis untuk mengisi celah penelitian kompresi tersebut (Baocai et al., 2026; Xia et al., 2022), kebaruan (*novelty*) dari penelitian ini terletak pada pelaksanaan studi komparatif dan fusi prapemrosesan multi-domain (ELA, CLAHE, dan SRM) pada arsitektur dangkal MesoNet (Afchar et al., 2018). Penelitian ini tidak hanya menguji masing-masing modul prapemrosesan secara terisolasi (Nazrin et al., 2025), tetapi juga mengintegrasikan ketiganya secara simultan ke dalam satu kesatuan kerangka kerja fusi multi-domain (Sabri &

Mstafa, 2026). Melalui pendekatan rekayasa berbasis data ini, performa model fusi akan dikomparasikan secara langsung terhadap model *baseline* (RGB mentah) dan model prapemrosesan tunggal, guna menciptakan sebuah *blueprint* sistem deteksi *deepfake* yang komputasionalnya ringan, transparan secara keputusan, dan memiliki ketahanan empiris yang absolut terhadap degradasi kualitas kompresi internet

2.2.Rumusan Masalah

Berdasarkan pemaparan latar belakang di atas, rumusan masalah dalam penelitian ini diformulasikan sebagai berikut:

1. Bagaimana proses implementasi strategi Pra-Pemrosesan Multi-Domain (melibatkan metode CLAHE, SRM, dan ELA) dalam mengekstraksi fitur anomali citra *deepfake* untuk mempersiapkan *dataset* pelatihan?
2. Bagaimana arsitektur MesoNet diimplementasikan dalam mengklasifikasikan citra *deepfake* berdasarkan *input* data yang telah melalui kerangka pra-pemrosesan multi-level?
3. Seberapa signifikan perbandingan tingkat kinerja antara model MesoNet murni (baseline), MesoNet teroptimasi prapemrosesan tunggal (ELA, CLAHE, SRM), dan MesoNet teroptimasi fusi multi-domain berdasarkan metrik evaluasi Confusion Matrix (Akurasi, Presisi, Recall, dan F1-Score)?

2.3.Batasan Masalah

Untuk menjaga agar penelitian tetap fokus dan terarah, ditetapkan batasan masalah sebagai berikut:

1. Data difokuskan pada citra diam (2D Image) berformat JPEG yang memuat manipulasi wajah (*deepfake face-swap*) dan citra sintetis AI, dengan populasi data yang dibatasi melalui teknik *sampling* guna menyeimbangkan memori komputasi. Penelitian ini tidak memproses file berekstensi video.
2. Teknik prapemrosesan difokuskan secara eksklusif pada pendekatan Pra-Pemrosesan Multi-Domain yang menerapkan metode CLAHE, filter SRM, dan ELA baik secara tunggal maupun dalam skema fusi.

3. Arsitektur jaringan saraf tiruan yang dikembangkan sebagai pengklasifikasi utama dibatasi pada model jaringan dangkal MesoNet, menggunakan *framework* TensorFlow dan Keras.
4. Kerangka evaluasi prapemrosesan secara eksklusif membandingkan lima skenario model masukan: citra RGB mentah (baseline), optimasi tunggal Error Level Analysis (ELA), optimasi tunggal Contrast Limited Adaptive Histogram Equalization (CLAHE), optimasi tunggal Spatial Rich Model (SRM), serta fusi integrasi dari ketiga metode prapemrosesan multi-domain tersebut

2.4.Tujuan Tugas Akhir

Adapun tujuan dilakukannya penelitian ini meliputi:

1. Mengimplementasikan kerangka kerja pra-pemrosesan multi-level (CLAHE, SRM, dan ELA) untuk mentransformasikan citra mentah menjadi peta representasi anomali forensik.
2. Membangun dan melatih model klasifikasi gambar menggunakan arsitektur *Deep Learning* MesoNet.
3. Mengevaluasi dan membandingkan ketahanan serta efisiensi klasifikasi arsitektur MesoNet murni (baseline), MesoNet teroptimasi prapemrosesan tunggal (ELA, CLAHE, SRM), dan MesoNet teroptimasi fusi multi-domain dalam membedakan citra wajah asli (real) dan manipulasi (fake).

2.5.Manfaat Tugas Akhir

Hasil eksperimen dari skripsi ini diharapkan memberikan kontribusi sebagai berikut:

1. **Manfaat Teoretis**

   Menawarkan pembuktian empiris dalam literatur *Computer Vision* bahwa manipulasi matriks piksel dengan ELA mampu difungsikan layaknya *attention mechanism* pasif yang memandu arsitektur konvolusi dangkal (MesoNet) untuk mengenali pemalsuan tanpa harus menambah kedalaman jaringan (*deep layer*).

2. **Manfaat Praktis**

   Melahirkan konfigurasi *blueprint* detektor hoaks visual berbasis AI yang berukuran sangat kecil (parameter ringan). Efisiensi ini memungkinkan implementasi perangkat lunak pada perangkat lokal yang mempunyai speksifikasi perangkat keras yang terbatas (*edge computing*).

BAB II
LANDASAN TEORI

2.6. Penelitian Terkait

Penelitian ini dikonstruksi berdasarkan evaluasi analitis terhadap sebelas literatur dan publikasi ilmiah *State-of-the-Art* (SOTA) dalam ranah *Computer Vision* dan Forensik Digital guna menemukan celah penelitian (*research gap*) yang dapat disempurnakan

No	Peneliti & Tahun	Judul	Model / Metode	Hasil / Kontribusi	Celah Penelitian
1	Joshi, D., et al. (2026)	*Enhanced MesoNet-based deepfake detection using deep learning*	MesoNet (Arsitektur Jaringan Dangkal)	Mengonfirmasi bahwa MesoNet masih menjadi kerangka kerja yang solid dan efisien untuk forensik multimedia modern.	Masih membutuhkan optimalisasi pada level masukan (*input*) agar fitur tidak hancur saat terkena kompresi internet.
2	Baocai, L., et al. (2026)	*Evaluating the real-world robustness of face-swap detection models under compression and noise*	Evaluasi Ketahanan Kompresi Lossy	Membuktikan bahwa CNN yang membaca piksel RGB mentah mengalami degradasi akurasi fatal akibat kompresi dunia nyata.	Tidak memberikan arsitektur *preprocessing* spesifik untuk menyelamatkan sinyal yang terkompresi.
3	Abbasi, M., et al. (2025)	*Comprehensive Evaluation of Deepfake Detection Models: Accuracy, Generalization...*	Studi Komparatif Model Deep Learning	Memberikan validasi rasional bahwa arsitektur jaringan *deepfake* menuntut efisiensi komputasi sekaligus kemampuan generalisasi lintas-domain.	Studi masih bersifat evaluasi makro; belum menyatukan fusi metode ELA dan MesoNet secara bersamaan.
4	Nazrin dkk. (2025)	*DeepForgery Images Detection Using Deep Learning Approaches and Error Level Analysis*	Pra-pemrosesan ELA + MesoNet vs ELA + VGG16	Membuktikan bahwa hibridisasi ELA-MesoNet (Akurasi 92,70%) lebih tangguh dan terhindar dari *overfitting* dibanding CNN masif seperti VGG16.	Masih mengandalkan ekstraksi ELA tunggal tanpa dukungan pemulihan tepi berbasis CLAHE maupun filter *noise* SRM.

No	Peneliti & Tahun	Judul	Model / Metode	Hasil / Kontribusi	Celah Penelitian
5	Gorle & Guttavelli (2025)	*Enhanced Image Tampering Detection using Error Level Analysis and CNN*	ELA + CNN vs VGG19, VGG16, ResNet	Mengintegrasikan ELA dengan CNN untuk mengekstrak fitur spasial dengan performa akurasi hingga 96,21%.	Menggunakan arsitektur CNN yang terlampau berat dan generik, kehilangan efisiensi parameter (*Green AI*).
6	Sadanand et al. (2024)	*Convolutional neural network-based techniques and error level analysis for image tamper detection*	Error Level Analysis (ELA) + CNN	Membuktikan bahwa metode simulasi kompresi ulang JPEG (ELA) secara forensik sangat tajam untuk mengekspos anomali citra digital.	Jaringan saraf yang digunakan tidak secara spesifik dirancang (dikalibrasi) untuk fitur anatomi wajah (*deepfake*).
7	Raković (2023)	*Error level analysis (ELA)*	Analisis matematis kompresi ulang JPEG	Menjelaskan kaidah matematis fundamental ELA dalam melacak inkonsistensi metadata kompresi *lossy*.	Fokus eksklusif pada pilar teoritis; belum merekayasanya secara komputasional menjadi tensor *input* bagi *deep learning*.
8	Xia, Z., dkk. (2022)	*Deepfake Video Detection Based on MesoNet with Preprocessing Module*	MesoNet + Preprocessing Module	Modul pra-pemrosesan terbukti mendongkrak performa deteksi dan melindungi fitur dari distorsi kompresi internet.	Modul tidak secara spesifik memanfaatkan galat kompresi JPEG (*Error Level*), melainkan filter frekuensi umum.
9	Gupta et al. (2022)	*Detection of tool based edited images from error level analysis and convolutional neural network*	Hibridisasi ELA + CNN	Mengonfirmasi bahwa representasi gambar ELA mampu melatih CNN menangkap pola anomali secara objektif.	Pengujian lebih berfokus pada manipulasi konvensional, belum mengarah pada fabrikasi *Generative AI*.
10	Sabri & Mstafa (2026)	*Curvelet-based frequency-aware feature enhancement for deepfake detection*	Analisis domain frekuensi (*Curvelet Transform*)	Menegaskan bahwa artefak generatif selalu meninggalkan cacat periodik di spektrum frekuensi tinggi.	Pendekatan matematika *curvelet* memberikan beban komputasi yang jauh lebih rumit dibandingkan metode

No	Peneliti & Tahun	Judul	Model / Metode	Hasil / Kontribusi	Celah Penelitian
					prapemrosesan filter spasial-frekuensi gabungan.
11	Das et al. (2021)	*Towards solving the deepfake problem: An analysis on improving deepfake detection using dynamic face augmentation*	Augmentasi Wajah Dinamis	Membantu meningkatkan generalisasi model dan mengatasi *class imbalance* selama masa pelatihan *deep learning*.	Orientasinya berpusat pada penambahan variasi data spasial (RGB), bukan pada penggalian jejak kompresi mikroskopis.

State of the Art (SOTA) secara mendasar terbelah menjadi dua pendekatan utama, yakni penggunaan arsitektur *Convolutional Neural Network* (CNN) berskala masif yang menawarkan tingkat akurasi tinggi namun menuntut beban sumber daya komputasi yang terlampau besar (Abbasi et al., 2025), serta pendekatan efisiensi komputasi yang memanfaatkan jaringan konvolusi dangkal (*shallow network*) seperti MesoNet yang secara spesifik dikalibrasi untuk mengekstraksi anomali mesoskopik pada anatomi wajah (Afchar et al., 2018). Mengingat adanya keterbatasan kapasitas komputasi laten pada arsitektur ringan seperti MesoNet, model komputasi ini mutlak memerlukan intervensi teknik prapemrosesan forensik—yang diakui sebagai SOTA di ranah *blind forensics*—untuk menyaring dan mengisolasi sinyal anomali secara eksplisit sebelum matriks gambar dikalkulasi oleh lapisan konvolusi (Xia et al., 2022). Berbagai modul prapemrosesan tersebut meliputi *Error Level Analysis* (ELA) untuk melacak inkonsistensi rasio kompresi (Raković, 2023), *Contrast Limited Adaptive Histogram Equalization* (CLAHE) untuk pemerataan kontras adaptif tanpa memperkuat derau alami, dan filter *Spatial Rich Model* (SRM) untuk menyaring residu derau frekuensi tinggi buatan *Generative AI* (Sabri & Mstafa, 2026).

Namun, dari kacamata analitis rekayasa perangkat lunak, formasi pemodelan ini menyisakan celah penelitian yang komputasionalnya sangat krusial ketika diimplementasikan pada skenario dunia nyata. Hal ini dibuktikan oleh fenomena anjloknya performa mayoritas model *deep learning* secara drastis

(*drop*) saat menghadapi serangan kompresi (*compression attacks*) homogen dari distribusi media sosial yang secara destruktif menghapus detail fitur frekuensi tinggi dan meratakan anomali piksel (Baocai et al., 2026; Xia et al., 2022). Meskipun modul-modul prapemrosesan ELA, CLAHE, dan SRM secara teoretis diakui keandalannya dalam mengekstrak fitur forensik, evaluasi komparatif mengenai metode mana yang paling tangguh (*robust*) dalam menopang dan mempertahankan akurasi MesoNet pada citra mentah (*raw*) dibandingkan citra terkompresi masih belum tereksplorasi secara memadai.

Sebagai sintesis analitis untuk menambal celah komputasional tersebut, posisi kebaruan (*novelty*) dari penelitian ini dirancang secara taktis melalui pelaksanaan studi komparatif berjenjang pada satu arsitektur dasar yang sama. Eksperimen ini secara spesifik membandingkan efektivitas MesoNet *baseline* (tanpa prapemrosesan) melawan MesoNet teroptimasi ELA (Raković, 2023), CLAHE, dan SRM (Sabri & Mstafa, 2026) secara tunggal, serta mengevaluasi performa kerangka kerja fusi integrasi multi-domain dari ketiga metode tersebut. Seluruh skenario pemodelan ini dievaluasi secara ketat pada dua kondisi uji dunia nyata: citra mentah (*raw uncompressed*) dan citra terkompresi, guna menemukan konfigurasi arsitektur yang memiliki ketahanan (*robustness*) tertinggi terhadap manipulasi siber (Baocai et al., 2026; Xia et al., 2022)."

2.7.Teori

Bagian ini menguraikan landasan konseptual dan arsitektur komputasional yang mendukung penyelesaian masalah deteksi deepfake guna menghindari redundansi dari pendekatan-pendekatan konvensional sebelumnya.

2.2.1. Deepfake dan Generative AI

Gil et al (2023) menjelaskan bahwa penciptaan konten *deepfake* secara fundamental dimotori oleh pemodelan prediktif berbasis *Deep Learning*, utamanya dengan mengoperasikan *Generative Adversarial Networks* (GANs) dan arsitektur *Autoencoders* bersilangan. Dalam skema komputasinya, jaringan dipaksa memampatkan ruang laten wajah dan merekonstruksinya ke target yang berbeda, sering kali melampaui

kemampuan persepsi visual mata telanjang manusia. Meskipun wajah terlihat sangat natural secara makroskopis, proses fusi piksel (*up-sampling*) secara inheren akan meninggalkan anomali struktural mikroskopis pada susunan grid matriks spasial. Jejak mikroskopis dan anomali struktural akibat proses sintesis algoritma AI ini menjadi sangat rentan dan terekspos secara jelas ketika citra digital tersebut berinteraksi dengan algoritma kompresi statis saat didistribusikan di ruang siber, khususnya pada format *lossy* seperti JPEG.

2.2.2. Mekanisme Dasar Kompresi Lossy JPEG

Teknik kompresi *Joint Photographic Experts Group* (JPEG) menggunakan skema *lossy compression* yang membuang sebagian informasi visual secara permanen. Secara algoritmik, format JPEG melakukan partisi citra ke dalam blok matriks diskrit berukuran 8x8 piksel (*Minimum Coded Units*). Setiap blok kemudian dienkode menggunakan operasi *Discrete Cosine Transform* (DCT) ke dalam domain frekuensi. Jika sebuah entitas asing (seperti wajah manipulatif AI) disisipkan ke dalam kanvas citra JPEG asli dan disimpan ulang, blok 8x8 pada area modifikasi tersebut akan kehilangan sinkronisasi dengan blok latar belakangnya (Sadanand et al., 2024). Kegagalan keselarasan atau inkonsistensi siklus kompresi antar blok matriks DCT tersebut bertindak sebagai pijakan operasional secara matematis bagi teknik forensik. Inkonsistensi ini membutuhkan alat analisis tingkat piksel, yakni *Error Level Analysis* (ELA), untuk memvisualisasikan letak manipulasi.

2.2.3. Konsep Forensik Error Level Analysis (ELA)

Raković (2023) merumuskan bahwa *Error Level Analysis* (ELA) adalah alat investigasi *blind digital forensics* yang mengeksekusi perhitungan galat dari riwayat tingkat kompresi tanpa memerlukan citra referensi asli. Metode ini mengeksploitasi laju degradasi piksel. Secara komputasi matematis, kalkulasi ELA didefinisikan melalui persamaan selisih absolut

$$I_{ELA} = \left| I_{orig} - JQ(I_{orig}) \right| \times \gamma$$

Di mana adalah representasi *input tensor* citra mentah, merupakan algoritma *resaving* citra ke dalam kompresi JPEG dengan skala kualitas statis (umumnya 90%), operator absolut menghitung selisih margin error per piksel, dan konstanta (*enhancer gain*) akan melipatgandakan kecerahan selisih tersebut. Proses penskalaan ini mengamplifikasi hasil galat kompresi, sehingga area yang dimanipulasi akan menghasilkan intensitas piksel anomali yang tinggi (high-intensity noise) dibandingkan dengan area latar belakang asliny. Meskipun peta anomali ELA ini sangat kontras, pembacaan manual oleh analis manusia sangat rentan terhadap subjektivitas. Oleh karena itu, peta ELA ini mutlak perlu diumpankan sebagai *tensor* masukan (sebagai *attention mechanism*) ke dalam arsitektur CNN yang dikhususkan untuk fitur wajah.

2.2.4. Arsitektur Convolutional Neural Network (CNN) MesoNet

Dalam menghadapi klasifikasi *image forgery*, arsitektur MesoNet yang didesain oleh Afchar et al. (2018) memecahkan masalah kompleksitas dengan menggunakan paradigma *shallow depth network* (jaringan konvolusi dangkal). MesoNet menargetkan observasi presisi pada area mesoskopik, yaitu tingkat fitur yang berada di antara derau mikroskopis dan batasan semantik makroskopis. Secara topologi, Meso-4 memindai matriks berdimensi 256x256 menggunakan empat blok konvolusional (Conv2D) secara berurutan. Setiap pasca-konvolusi disematkan optimasi *Batch Normalization* guna menstabilkan gradien sebaran matriks selama pelatihan, dan diaktivasi oleh fungsi *Rectified Linear Unit* (ReLU) serta *MaxPooling2D* untuk mereduksi dimensi spasial fitur gambar. Walaupun kerangka lapisan konvolusi MesoNet ini telah terbukti efisien oleh Joshi et al. (2026), lapisan klasifikasi akhirnya secara bawaan masih menggunakan perataan linear (*Flatten*). Hal ini memaksa penciptaan puluhan ribu parameter koneksi yang rawan memicu *overfitting*, sehingga menuntut intervensi rekayasa struktural lebih lanjut.

2.2.5. Optimasi Global Average Pooling 2D (GAP)

Penelitian sebelumnya kerap mengalami kegagalan akibat model yang menghafal fitur pelatihan secara membabi buta (*overfitting*), yang mayoritas dipicu oleh penggunaan fungsi operasional *Flatten* di ujung arsitektur jaringan (Das et al., 2021). Operator *Flatten* yang meratakan tensor 2D menjadi vektor 1D memaksa penciptaan ratusan ribu bobot (*weights*) saat dihubungkan ke lapisan *Dense* tersembunyi. Sebagai intervensi arsitektural *Green AI*, ujung perataan pada MesoNet disubstitusikan secara penuh menggunakan agregasi matematis *Global Average Pooling 2D* (GAP). Metode GAP meniadakan proses penderetan linier dengan mengekstraksi satu nilai rata-rata skalar (*spatial average*) murni dari setiap lembar filter 2D matriks konvolusi. Restrukturisasi ini berhasil memangkas seluruh beban komputasi laten secara eksponensial hingga menyisakan parameter aktif yang sangat minim (~12.137 parameter), meniadakan risiko *overfitting*, dan sangat menghemat memori. Setelah kerangka komputasi MesoNet berhasil direkayasa menjadi arsitektur yang sangat ringan dan adaptif melalui GAP, model dihadapkan pada tahap pengujian. Untuk membuktikan efektivitas klasifikasi secara saintifik, kinerja model mutlak harus divalidasi menggunakan instrumen statistik prediktif.

2.2.6. Matriks Evaluasi Kinerja

Pengukuran keandalan arsitektur *Machine Learning* dalam disiplin forensik digital tidak dikuantifikasi secara perseptual, melainkan melalui distribusi statistik pada instrumen *Confusion Matrix* (Matriks Kebingungan). Tabulasi ini mengklasifikasikan inferensi sistem ke dalam *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Berdasarkan elemen tersebut, metrik analitik diturunkan ke dalam persamaan matematis

1. **Accuracy (Akurasi)**

   Perhitungan proporsi ketepatan prediksi model secara keseluruhan, dirumuskan melalui

$$\frac{TP+TN}{FP+FN+TP+TN}$$

2. **Precision (Presisi)**

Kredibilitas kehati-hatian, merepresentasikan seberapa dapat dipercaya keputusan algoritma saat melabeli citra sebagai manipulasi, dirumuskan melalui

$$\frac{TP}{TP+FP}$$

3. **Recall (Sensitivitas)**

Probabilitas daya sapu sistem, mendefinisikan seberapa banyak ancaman pemalsuan *deepfake* yang sukses teridentifikasi dari seluruh kumpulan data uji, dirumuskan melalui

$$\frac{TP}{TP+FN}$$

4. **F1-Score**

Perhitungan rata-rata harmonik (*harmonic mean*) yang digunakan untuk mengevaluasi ekulibrium keseimbangan kinerja model antara nilai *Precision* dan *Recall*.

2.2.7. Integrasi Pra-Pemrosesan Multi-Domain pada Arsitektur MesoNet

Meskipun arsitektur jaringan konvolusi dangkal (*shallow network*) seperti MesoNet terbukti sangat efisien dalam menekan jumlah parameter komputasi, desain struktural ini memiliki keterbatasan kapasitas laten secara inheren (Afchar et al., 2018). MesoNet tidak memiliki ruang parameter yang cukup memadai untuk secara mandiri mengekstrak atau merestorasi sinyal anomali dari citra yang telah terdegradasi secara parah (Xia et al., 2022). Keterbatasan ekstraksi fitur (computational bottleneck) ini mengharuskan arsitektur MesoNet untuk diintegrasikan dengan

intervensi pra-pemrosesan multi-domain guna menutupi kebutaan spasial dan kegagalan ekstraksi frekuensi saat menghadapi skenario manipulasi dunia nyata (Baocai et al., 2026; Xia et al., 2022).

1. **Kebutaan Spasial Terhadap Degradasi Tepi Akibat Kompresi**

   Kelemahan pertama terletak pada kerentanan MesoNet terhadap *smoothing attack* yang dipicu oleh algoritma kompresi *lossy* tingkat lanjut dari platform media sosial (Baocai et al., 2026). MesoNet beroperasi secara eksklusif untuk mencari anomali struktural tingkat menengah (mesoskopik), seperti ketidakkonsistenan halus pada batas penyatuan wajah (*blending*) (Afchar et al., 2018). Namun, kompresi secara destruktif meratakan fitur frekuensi tinggi dan mengaburkan batas transisi spasial tersebut, menyebabkan lapisan konvolusi awal MesoNet kehilangan fitur panduannya (Xia et al., 2022).

   Sebagai solusi pemulihan data, *Contrast Limited Adaptive Histogram Equalization* (CLAHE) diimplementasikan. Berbeda dengan ekualisasi histogram global yang berisiko memperkuat derau (*noise*), CLAHE mempartisi matriks citra ke dalam ubin-ubin lokal *non-overlapping* (umumnya berdimensi 8x8 piksel) dan menajamkan kontras secara adaptif. Proses komputasional ini merestorasi batas tekstur wajah dan ketidakkonsistenan gradien pencahayaan yang kabur akibat kompresi tanpa mendistorsi kromatisitas asli citra. Dengan menyajikan representasi spasial yang tajam, CLAHE secara krusial mendongkrak sensitivitas MesoNet dalam mendeteksi anomali batas manipulasi pada citra dengan kualitas yang telah terdegradasi.

2. **Kegagalan Mengekstrak "Sidik Jari" Generatif AI**

   Kelemahan kedua berkaitan dengan keterbatasan fungsional MesoNet dan *Error Level Analysis* (ELA) saat dihadapkan pada citra yang sepenuhnya disintesis oleh *Generative AI* modern, seperti model

Diffusion atau GANs (Abbasi et al., 2025). ELA berfokus pada pelacakan diskontinuitas rasio kompresi piksel yang menjadi ciri khas manipulasi *splicing* atau penyisipan gambar (Raković, 2023; Sadanand et al., 2024). Namun, citra sintetis penuh yang digenerasi dari kanvas kosong sering kali memiliki tingkat kompresi yang seragam dan modifikasi spasial yang sangat mulus tanpa batas *seams* (Sabri & Mstafa, 2026). Akibatnya, baik ELA maupun lapisan konvolusi spasial MesoNet kerap kali gagal mengidentifikasi kepalsuan pada citra jenis ini (Baocai et al., 2026).

Guna mengeliminasi kelemahan tersebut, ekstraksi domain frekuensi melalui filter *Spatial Rich Model* (SRM) diintegrasikan. Proses sintesis oleh kecerdasan buatan generatif secara inheren selalu meninggalkan residu cacat periodik pada spektrum frekuensi tinggi akibat operasi fusi piksel atau *up-sampling* (Sabri & Mstafa, 2026). Kumpulan filter lolos-tinggi (*high-pass filters*) pada SRM dirancang secara radikal untuk menekan informasi semantik makroskopis wajah dan secara eksklusif mengekstrak "sidik jari" residu derau frekuensi tinggi buatan AI. Integrasi representasi filter SRM ini memberikan suplai informasi anomali frekuensi yang luput dari deteksi ELA, sehingga memandu arsitektur MesoNet untuk mempercepat konvergensi dalam melacak fabrikasi kecerdasan buatan yang mutakhir (Joshi et al., 2026).

BAB III
METODOLOGI PELAKSANAAN

3.1. Tempat Dan Waktu Pelaksanaan

Penelitian ini dilaksanakan secara komputasional, tanpa melibatkan pengumpulan dataset tambahan. Seluruh tahapan penelitian dijalankan secara daring dan local menggunakan perangkat keras pribadi. Adapun waktu pelaksanaan penelitian dimulai pada bulan Juli 2026 dan direncanakan selesai pada Desember 2026. Lokasi penelitian sepenuhnya berlangsung secara hibrid di kediaman yang berlokasi di Kota Manado, Sulawesi Utara dan berlokasi di Jurusan Teknik Elektro, Universitas Sam Ratulangi dengan pemantauan dan bimbingan oleh dosen pembimbing.

	Bulan 1	Bulan 2	Bulan 3	Bulan 4	Bulan 5	Bulan 6
Studi Literatur & Identifikasi Masalah						
Pengumpulan & Pengambilan Dataset (Data Harvesting)						
Pemfilteran & Penyeimbangan Data (Smart Sampling)						
Pra-Pemrosesan Citra Multi-						

Domain (Preprocessing)						
Partisi Dataset (Data Splitting)						
Pembangunan Arsitektur Model (Model Construction)						
Pelatihan & Optimasi Model (Model Training & Callbacks)						
Pengujian & Evaluasi Kinerja (Testing & Evaluation)						
Analisis Komparatif & Visualisasi (Interpretability)						
Finalisasi & Penyusunan Laporan						

3.2. Alat dan Bahan

No	Komponen	Spesifikasi	Penggunaan
1.	Laptop	AMD Athlon Silver 3050U with Radeon Graphics, 2,30 GHz, RAM 4,00 GB (3,21 GB usable), kecepatan 2400 MHz	Laptop pribadi (personal computer), digunakan untuk penulisan kode, eksplorasi data, dan penyusunan laporan
2.	Python	Python 3.12.13	Bahasa pemrograman utama yang digunakan untuk mengimplementasikan seluruh alur penelitian
3.	Google Collab	TensorFlow 2.20.0 Keras 3.13.2 OpenCV (cv2) 4.13.0 Pillow (PIL) 11.3.0 SciPy 1.16.3 Scikit-learn 1.6.1 NumPy 2.0.2 Pandas 2.2.2 Matplotlib 3.10.0 Seaborn 0.13.2 KaggleHub 1.0.2 Hard 3.13.2	Digunakan sebagai lingkungan pengembangan dan eksekusi kode berbasis cloud. Memungkinkan akses ke sumber daya komputasi yang lebih kuat (GPU) untuk melatih model machine learning atau deep learning yang memerlukan daya komputasi tinggi, tanpa bergantung sepenuhnya pada spesifikasi laptop lokal. Juga memfasilitasi kolaboras
4.	Github	git version 2.43.0.windows.1	Digunakan untuk menyimpan, melacak perubahan, serta membagikan proyek penelitian secara terbuka. Juga memudahkan dokumentasi serta kolaborasi dengan sistem versioning dan issue tracking

3.3. Alur Penelitian

DAFTAR PUSTAKA

Abbasi, M., Váz, P., Silva, J., & Martins, P. (2025). Comprehensive evaluation of deepfake detection models: Accuracy, generalization, and resilience to adversarial attacks. *Applied Sciences*, 15(3), 1225. https://doi.org/10.3390/app15031225

Afchar, D., Nozick, V., Yamagishi, J., & Echizen, I. (2018). MesoNet: A compact facial video forgery detection network. *2018 IEEE International Workshop on Information Forensics and Security (WIFS)*, 1-7. https://doi.org/10.1109/WIFS.2018.8630761

Baocai, L., Azzali, F. B., & Farid, H. (2026). Evaluating the real-world robustness of face-swap detection models under compression and noise. *Frontiers in Artificial Intelligence*, 9.

Das, S., Seferbekov, S., Datta, A., Islam, M. S., & Amin, M. R. (2021). Towards solving the deepfake problem: An analysis on improving deepfake detection using dynamic face augmentation. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*, 3776-3785. https://doi.org/10.1109/ICCVW54120.2021.00421

Gil, R., Virgili-Gomà, J., López-Gil, J.-M., & García, R. (2023). Deepfakes: Evolution and trends. *Soft Computing*, *27*, 11295–11318. https://doi.org/10.1007/s00500-023-08605-y

Gorle, R., & Guttavelli, A. (2025). Enhanced image tampering detection using error level analysis and a CNN. *Technology and Applied Science Research*, 15(1), 19683–19689. https://doi.org/10.48084/etasr.9593

Gunawan, T. S., Hanafiah, S. A. M., Kartiwi, M., Ismail, N., Za'bah, N. F., & Nordin, A. N. (2017). Development of photo forensics algorithm by detecting photoshop manipulation using error level analysis. *Indonesian Journal of Electrical Engineering and Computer Science*, *7*(1), 131–137. https://doi.org/10.11591/ijeecs.v7.i1.pp131-137

Gupta, A., Joshi, R., & Laban, R. (2022). Detection of tool based edited images from error level analysis and convolutional neural network. *arXiv*. https://doi.org/10.48550/arXiv.2204.09075

Joshi, D., Kashyap, A., & Arora, P. (2026). Enhanced MesoNet-based deepfake detection using deep learning: A robust framework for multimedia forensics. *Journal of Forensic Sciences*, 71(2), 785-798. https://doi.org/10.1111/1556-4029.70275

Nazrin, S. N., Burhanuddin, L. A., Jothi, N., Zaman, H. B., & Rosnan, M. F. B. (2025). DeepForgery images detection using deep learning approaches and error level analysis. *JOIV: International Journal on Informatics Visualization*, 9(2), 528-533. https://doi.org/10.62527/joiv.9.2.3504

Raković, D. (2023). Error level analysis (ELA). *Tehnika*, 78(4), 445-451. https://doi.org/10.5937/tehnika2304445r

Sabri, S. A., & Mstafa, R. J. (2026). Curvelet-based frequency-aware feature enhancement for deepfake detection. *Science Journal of University of Zakho*, 14(2), 386-395.

Sadanand, V. S., Janardhana, S. S., Purushothaman, S., Hande, S., & Prakash, R. (2024). Convolutional neural network-based techniques and error level analysis for image tamper detection. *Indonesian Journal of Electrical Engineering and Computer Science*, 33(2), 1100–1107. https://doi.org/10.11591/ijeecs.v33.i2.pp1100-1107

Xia, Z., Qiao, T., Xu, M., Wu, X., Han, L., & Chen, Y. (2022). Deepfake video detection based on MesoNet with preprocessing module. *Symmetry*, 14(5), 939. https://doi.org/10.3390/sym14050939